

Greedy Sparse Least-Squares SVM

Сон Артём

11 апреля 2024 г.

Постановка задачи

- ▶ Пусть дано множество тренировочных данных:
 $\mathcal{D} = (x_i, y_i)_{i=1}^l, x_i \in \mathcal{X} \subset \mathbb{R}^d, y_i \in \mathcal{Y} \subset \mathbb{R}$
- ▶ Необходимо найти функцию $f(x)$, которая наилучшим образом предсказывает новые наблюдения.
- ▶ Модель нелинейной регрессии с квадратичной функцией потерь задается следующим образом:
 - ▶ $\mathcal{K}(x, x') = \phi(x) \cdot \phi(x')$, - ядерная функция
 - ▶ $\mathcal{K} : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$
 - ▶ $\phi : \mathcal{X} \rightarrow \mathcal{F}$, \mathcal{F} - пространство признаков высшей размерности
 - ▶ $W_{LS-SVM}(w, b) = \frac{1}{2} \|w\|^2 + \frac{\gamma}{l} \sum_{i=1}^l (y_i - w \cdot \phi(x_i) + b)^2$ - целевая функция модели, $w = \sum_{i=1}^l \alpha_i \phi(x_i)$
 - ▶ $f(x) = \sum_{i=1}^l \alpha_i \mathcal{K}(x_i, x) + b$ - решающая функция, полученная минимизацией целевой функции.

Идея алгоритма

- ▶ Пусть даны тренировочные данные:
 $\mathcal{D} = (x_i, y_i)_{i=1}^l, x_i \in \mathcal{X} \subset \mathbb{R}^d, y_i \in \mathcal{Y} \subset \mathbb{R}$
- ▶ Дана модель нелинейной регрессии с квадратичной функции потерь, с ядерной функцией $\mathcal{K} : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$, определяющую коэффициенты $\{b, \alpha_i\}_{i=1}^l \subset \mathbb{R}$ решающей функции
 $f(x) = \sum_{i=1}^l \alpha_i \mathcal{K}(x_i, x) + b$, минимизируя целевую функцию модели

Мы хотим найти такое приближение, что для некоторого подмножества $S \subset \{1, \dots, l\}$, коэффициенты $\{b, \beta_i\}_{i=1}^l \subset \mathbb{R}$ будут минимизировать функцию цели $f(x) = \sum_{i \in S} \beta_i \mathcal{K}(x_i, x) + b$ нашей GSLS-SVM модели с параметром регуляризации γ :

$$\mathcal{L}(\beta, b) = \frac{1}{2} \sum_{i,j \in S} \beta_i \beta_j \mathcal{K}(x_i, x_j) + \frac{\gamma}{l} \sum_{i=1}^l (y_i - \sum_{j \in S} \beta_j \mathcal{K}(x_i, x_j))^2$$

Алгоритм. Жадность

- ▶ Каждую итерацию GSLS выбирается новый вектор из датасета в качестве опорного
- ▶ Вычисляется целевая функция, и лучший на данной итерации опорный вектор добавляется к результирующему подмножеству.
- ▶ Процесс завершается, когда в подмножество достигло некоторого предопределенного размера.

Алгоритм. Вычисления (1)

$$\mathcal{L}(\beta, b) = \frac{1}{2} \sum_{i,j \in S} \beta_i \beta_j \mathcal{K}(x_i, x_j) + \frac{\gamma}{l} \sum_{i=1}^l (y_i - \sum_{j \in S} \beta_j \mathcal{K}(x_i, x_j))^2$$

Если приравнять частные производные по β и b нулю, и разделить на $2\gamma/l$, получим:

$$\sum_{i \in S} \beta_i \sum_{j=1}^l k_{ij} + lb = \sum_{j=1}^l y_j$$

и

$$\sum_{i \in S} \beta_i \left\{ \frac{l}{2\gamma} k_{ir} + \sum_{j=1}^l k_{jr} k_{ji} \right\} + b \sum_{i=1}^l k_{ir} = \sum_{i=1}^l y_i k_{ir} \quad \forall r \in S$$

Алгоритм. Вычисления (2)

Эти уравнения представляют из себя СЛАУ с $|S| + 1$ уравнениями и неизвестными. В матричной форме:

$$H \begin{bmatrix} \beta \\ b \end{bmatrix} = \begin{bmatrix} \Omega & \Phi \\ \Phi^T & l \end{bmatrix} \begin{bmatrix} \beta \\ b \end{bmatrix} = \begin{bmatrix} c \\ \sum_{k=1}^l y_k \end{bmatrix},$$

$$\text{где } \Omega = \left[\frac{l}{2\gamma} k_{ij} + \sum_{r=1}^l k_{rj} k_{ri} \right]_{i,j \in S},$$

$$\Phi = \left(\sum_{j=1}^l k_{ij} \right)_{i \in S},$$

$$c = \left(\sum_{j=1}^l y_j k_{ij} \right)_{i \in S},$$

$$k_{ij} = \mathcal{K}(x_i, x_j)$$

Псевдокод

Data: $\mathcal{K}, \mathcal{X}, \mathcal{Y}, sv_num$

Result: $S, \beta_{best}, b_{best}$

$l = |\mathcal{X}|, \mathcal{L}_{best} = \infty;$

$S, \beta_{best}, b_{best}, index_{best} = \{\};$

while $|S| \neq sv_num$ **do**

for $j \in \mathcal{X} \setminus S$ **do**

$S \leftarrow j;$

 compute $\Omega, \Phi, c, H;$

$(\beta, b) = H^{-1} * (\sum_{k=1}^l y_k, c);$

$L = \mathcal{L}(\beta, b);$

if $L < \mathcal{L}_{best}$ **then**

$\beta_{best}, b_{best}, \mathcal{L}_{best}, index_{best} = \beta, b, L, j;$

$S \rightarrow j;$

$S \leftarrow index_{best};$

Результаты